SPORTS VISION | STAND OP 28 OKTOBER 2026

Projectuitleg en mondelinge verdediging

Deze gids legt ons voetbalproject eenvoudig uit, schat de mogelijke beoordeling in en helpt je oefenen voor het mondeling. De antwoorden zijn voorbeelden om te begrijpen en in je eigen woorden uit te leggen.

Mijn huidige inschatting is 13-15 op 20, met ongeveer 14 op 20 als richtpunt. Dat veronderstelt een redelijke eigen uitleg en een werkende demonstratie. Dit is een onderbouwde raming, geen beoordeling van de docent. Jouw mondelinge beheersing en de checkpoints heb ik niet kunnen beoordelen.

Officieel onderdeel	Gewicht	Voorbeeldraming
Data en annotatiestrategie	25	16 / 25
Modellering en fine-tuning	35	26 / 35
Foutanalyse	20	14 / 20
Pipeline en homography	10	7 / 10
Proces en eigenaarschap bij GenAI	10	6 / 10
Totaal van dit schattingsvoorbeeld	100	69 / 100 = 13,8 / 20

Wat al sterk is: echte fine-tuning, vastgelegde modelvergelijkingen, foutvoorbeelden, gescheiden wedstrijden, een werkende softwareketen en een eenvoudiger schoolmodus.

Wat nog punten kan kosten: de eigen menselijke labelbijdrage en review zijn nog niet aangetoond; de nieuwe schoolwerkkopie is nog niet menselijk nagekeken. De eenvoudige keten is technisch getest, maar een door jou beoordeelde volledige demonstratie is nog niet aangetoond in de beschikbare rapporten. De uitgebreide automatische functies hebben bekende fouten.

Potentieel na gerichte afwerking: ongeveer 16-17 op 20 bij sterke eigen uitleg, echte labelcorrecties en een overtuigende MVP-demo. De opdracht noemt tot 85% voor een degelijk MVP met goede analyse: dat is 17/20. Boven 85% moet je minstens een uitbreiding succesvol uitvoeren en verdedigen; extra code alleen volstaat niet.

De tabel op pagina 4 van de opdracht beschrijft per onderdeel wat je mondeling moet kunnen uitleggen. Ze bevat geen letterlijke lijst examenvragen. De vragen in deze gids zijn daarvan afgeleid en aangevuld met vragen over onze concrete code.

OVERZICHT | BEGRIJP EERST DE BASIS

Het project in een minuut

Een voetbalvideo wordt omgezet in detecties en een bovenaanzicht van het veld. De basis gebruikt twee bestaande YOLO-modellen: P006 voor spelers en scheidsrechters, en F005 voor de bal. Een handmatig berekende homography zet de voetpunten van spelers om naar veldposities.

Volgorde: MP4 lezen > YOLO-detecties > voetpunt kiezen > projectie naar veld > video en minimap samen tonen.

1. Wat is het probleem dat jullie oplossen?

In een camerabeeld lijken afstanden en spelersgroottes verschillend door het perspectief. Wij detecteren de deelnemers en tonen hun posities op een vast bovenaanzicht. Zo wordt hun plaats op het veld overzichtelijker.

2. Waarom hebben jullie een aparte schoolmodus?

De opdracht vraagt eerst een betrouwbare basis met een vaste camera. Die modus houdt de werking overzichtelijk: handmatige veldpunten, detectie en minimap. Tracking, teams en automatische veldherkenning zijn afzonderlijke uitbreidingen.

3. Waarvoor gebruiken jullie de verschillende programmaonderdelen?

OpenCV leest beelden en voert de geometrische transformatie uit. YOLO voorspelt objectboxen en klassen. Streamlit is de lokale gebruikersinterface. Onze Python-code verbindt deze stappen en bewaart uitvoer en instellingen.

4. Wat is het verschil tussen het model en de pipeline?

Het model voorspelt bijvoorbeeld een spelerbox in een beeld. De pipeline omvat daarnaast het inlezen van video, drempels, kalibratie, projectie, weergave en opslag. Een goed model garandeert dus niet dat de hele minimap correct is.

Starten vanuit de projectmap
`.\scripts\Start-School.ps1`
Zonder GPU: voeg `-Device cpu` toe. De optionele balroute met tegels start met `-BroadcastTiles`.

Bestanden die je moet kunnen aanwijzen
streamlit_app.py: interface.
src/football_pipeline/detection.py: detecties.
src/football_pipeline/geometry.py: homography en projectie.
src/football_pipeline/pipeline.py: de volledige verwerking.
configs/models-school.json: modellen en instellingen.

Route door deze gids: data op de volgende twee pagina's; daarna modelwerking, training, metingen, fouten, homography, demonstratie, uitbreidingen en jouw eigenaarschap.

DATA EN ANNOTATIESTRATEGIE | 25 PROCENT

Goede labels en een eerlijke verdeling

De docent verwacht dat je labelregels, moeilijke situaties en de verdeling tussen training en validatie kunt verantwoorden. Leg vooral uit hoe fouten in labels het leren beïnvloeden.

5. Wat is een annotatie of label?

Voor objectdetectie is dat een klasse, bijvoorbeeld bal, en een rechthoek rond het object. Een box vertelt het model niet alleen wat er zichtbaar is, maar ook waar het staat. Een verkeerd label wordt tijdens training een verkeerd leerdoel.

6. Hoe ziet een YOLO-label eruit?

Elke regel bevat de klasse-ID, het midden x en y, en de breedte en hoogte. De vier coördinaten zijn gedeeld door de beeldbreedte of -hoogte en liggen daardoor ongeveer tussen 0 en 1. Dit zijn boxcoördinaten in het beeld, geen veldcoördinaten.

7. Hoe zorgen jullie dat iedereen op dezelfde manier labelt?

Gebruik dezelfde klassen en afspraken over strakke boxen, bedekking en twijfel. Controleer het volledige beeld op ontbrekende doelobjecten. Bewaar correcties en laat een ander teamlid ze nakijken. De menselijke review van onze nieuwe werkkopie staat nog open.

8. Wat doe je bij een wazige of deels bedekte bal?

Label alleen als de zichtbare bal betrouwbaar te lokaliseren is en pas de gekozen boxregel consequent toe. Verzin geen positie bij volledige onzichtbaarheid. Een onbeslisbaar beeld kan beter buiten een volgende trainingsversie blijven dan een fout label krijgen.

9. Waarom mag je niet gewoon willekeurig videoframes over de splits verdelen?

Frames kort na elkaar kunnen bijna identiek zijn. Als ze in training en validatie belanden, lijkt het model beter te generaliseren dan het werkelijk doet. Onze nieuwe broadcastselecties houden wedstrijden gescheiden tussen training en validatie.

10. Is een beeld zonder label automatisch een negatief voorbeeld?

Nee. Het label kan gewoon ontbreken. Een negatief voorbeeld is pas bruikbaar nadat het volledige beeld gecontroleerd is en er geen doelobject zichtbaar blijkt. Twijfelachtige beelden zijn geen betrouwbare negatieven.

11. Moet er volgens de PDF verplicht een aparte testset zijn?

De PDF vraagt expliciet een train/valstrategie en degelijke validatie. Ze schrijft niet letterlijk een derde split voor. Onze projectvalidator stelt die extra eis voor een volledige eindevaluatie. Een verse testset versterkt onafhankelijke claims, maar is geen afzonderlijke officiële rubricregel.

DATA | HOUD DE VERSCHILLENDE SELECTIES UIT ELKAAR

Onze datasets en jouw eigen bijdrage

Selectie	Omvang en rol
P006 spelerexperiment	60 trainingsbeelden en 20 validatiebeelden; 3 andere wedstrijden per split.
Grote SN-GSR-broadcastset	8.000 bronbeelden: 6.000 training en 2.000 validatie. Aanvullende data, geen bewijs van een nieuwe spelertraining.
AI-gecurateerde balset	132 oorspronkelijke beelden. Hieruit kwamen de crops voor de v2-baltraining.
Broadcastbal v2 crops	197 training en 85 validatie, inclusief 34 gecontroleerde negatieve crops over beide splits.
Jouw schoolwerkkopie	80 bestaande balbeelden: 48 training en 32 validatie. Alle beginnen positief; menselijke review staat open.

12. Op welke 80 beelden hebben jullie het balmodel getraind?

Let op de aanname: de nieuwe werkkopie van 80 beelden is bedoeld voor mijn eigen review en is nog niet als zo'n nieuwe trainingsronde uitgevoerd. Broadcastbal v2 werd echt getraind op 197 crops uit de grotere gecureerde set. Ik mag die twee experimenten niet verwarren.

13. Zijn 8.000 beelden automatisch beter dan 80 beelden?

Nee. Relevantie, variatie en labelkwaliteit tellen. Veel bijna gelijke frames voegen weinig toe en verkeerde boxen leren verkeerde locaties aan. De opdracht vraagt een gerichte eigen bijdrage van 40-80 uitdagende frames; de grote verzameling vervangt die bijdrage niet.

14. Welke echte labelcorrectie kun je als voorbeeld uitleggen?

Bij SNGS-097_000376 lag de oorspronkelijke balbox boven de zichtbare bal. De AI-curatie verplaatste de box van [935,446,949,460] naar [932,456,947,471] in pixels. Dat toont het probleem, maar telt niet als een door mij uitgevoerde menselijke correctie.

15. Wat moet je zelf nog doen aan de labels?

Open de 80-framewerkkopie, controleer beelden en corrigeer aantoonbare fouten onder je eigen naam. Laat een ander teamlid reviewen. Bewaar voor/na-voorbeelden en je labelafspraak. Na echte wijzigingen moet een volgende trainings- en meetronde een nieuwe datasetversie gebruiken.

16. Waarom zijn de werkkopieën gescheiden van de oude experimentdata?

Zo veranderen mijn correcties de oude trainingsdata en bijbehorende resultaten niet stilzwijgend. De selectie heeft eigen bestanden en een manifest. Checksums helpen veranderingen vaststellen; ze bewijzen niet dat een label inhoudelijk juist is.

Werkkopie: data/school-ball80-review-v1/manifest.json. De controle vindt geen inhoudelijke menselijke review en geen testsplit. Er zijn nul gereviewde frames in deze werkkopie. De 132 bronbeelden en 80 kopieën mogen niet als extra unieke foto's worden opgeteld.

MODELLERING EN FINE-TUNING | 35 PROCENT

Hoe YOLO leert herkennen

De docent verwacht begrip van de visionarchitectuur, het leerproces en de gemaakte trainingskeuzes. Je hoeft de bibliotheek niet volledig zelf te herschrijven, maar wel uit te leggen wat erin gebeurt.

17. Wat doet YOLO precies?

YOLO is een neuraal netwerk voor objectdetectie. Het verwerkt een beeld en voorspelt boxen, klassen en scores. Het doet dus meer dan zeggen dat er ergens een speler in het beeld staat: het probeert ook diens locatie te vinden.

18. Wat doet een convolutioneel netwerk daarbij?

Convolutiefilters zoeken lokale patronen, zoals randen en texturen. Dieper in het netwerk worden die kenmerken gecombineerd tot complexere vormen. Een detectiekop gebruikt zulke kenmerken om locaties en klassen te voorspellen.

19. Wat betekenen backbone, neck en head op hoofdlijnen?

De backbone haalt beeldkenmerken uit de invoer. De neck combineert kenmerken op verschillende schalen. De head maakt de detectievoorspellingen. Het onderscheid helpt verklaren waarom detailverlies en de schaal van objecten de uitkomst beïnvloeden.

20. Wat is transfer learning?

We beginnen met bestaande gewichten die al nuttige beeldkenmerken hebben geleerd. Fine-tuning past die verder aan onze voetbaltaak aan. Dat is haalbaarder met beperkte data dan helemaal vanaf willekeurige gewichten te beginnen.

21. Hoe worden de gewichten aangepast?

Eerst voorspelt het model iets. De loss vergelijkt die voorspelling met de labels. Backpropagation berekent hoe gewichten aan de fout bijdragen. De optimizer past ze met een beperkte stap aan. Dat herhaalt zich over batches.

22. Welke fouten meten de losses in jullie baltraining?

De logs bevatten box_loss, cls_loss en dfl_loss. Ze betreffen respectievelijk lokalisatie, de klassevoorspelling en een extra onderdeel van de boxlokalisatie. Het zijn trainingsdoelen. Een dalende loss is nog geen bewijs dat detecties op andere wedstrijden beter zijn.

23. Waarom mag je een algemene person-detectie niet gewoon player noemen?

Een persoon kan ook een scheidsrechter, trainer of supporter zijn. Anders benoemen creëert geen geleerde rolherkenning. Ons schoolprofiel gebruikt daarom de expliciete player- en referee-uitvoer van P006 en alleen de echte balklasse van het balmodel.

FINE-TUNING | MAAK ONDERSCHEID TUSSEN DE EXPERIMENTEN

Onze trainingskeuzes kunnen uitleggen

P006: start van pretrained YOLO11n; 60 trainbeelden en 20 validatiebeelden; de cursusronde vergelijkt onder meer zonder en met augmentatie. Er was een maximum van 60 epochs en early stopping na 12 epochs zonder verbetering. Maximum is niet hetzelfde als werkelijk uitgevoerde epochs.

Broadcastbal v2: start van F005; werkelijk 12 epochs, batch 4, invoer 640, eerste 10 lagen vast en AdamW met basisleertempo 0,0001. Er zijn onder meer beperkte kleurvariaties en horizontale spiegeling; mosaic, mixup en schaalaugmentatie staan uit. De exacte instellingen staan in de opgeslagen args.yaml.

24. Wat is het verschil tussen een epoch en een batch?

Een epoch is een volledige ronde door de trainingsbeelden. Een batch is een kleinere groep waarmee een update wordt berekend. Bij batch 4 verwerkt de training dus groepen van vier beelden; dat betekent niet vier epochs.

25. Wat doet de learning rate?

Die bepaalt hoe groot de updates zijn. Een te groot leertempo kan het leren instabiel maken; een te klein leertempo kan langzaam aanpassen. De basiswaarde is niet noodzakelijk de waarde op elke stap, omdat warmup en een leerschema die veranderen.

26. Waarom staan de eerste lagen vast?

Die behouden dan hun eerder geleerde kenmerken. Alleen latere delen passen zich aan. Dat beperkt de aanpassing bij kleine datasets en verlaagt de trainingslast. Het is een keuze die je met validatie moet beoordelen, geen garantie tegen overfitting.

27. Waarom gebruik je augmentatie?

Ze voegt realistische variatie toe, zoals een gespiegeld beeld of beperkte kleurverandering. De boxen moeten correct mee veranderen. Onrealistische vervormingen of zwaar detailverlies kunnen een kleine bal juist moeilijker maken.

28. Hoe herken je overfitting?

De trainingsfout blijft verbeteren terwijl resultaten op de validatieset stagneren of verslechteren. Bekijk dus beide, samen met echte voorbeelden. Ook een gelekte train/valverdeling kan een misleidend gunstige validatie opleveren.

29. Waarom heet de optimizer AdamW en niet gewoon Adam uit de les?

AdamW is een variant van Adam met afzonderlijke weight decay. De onderliggende gedachte van optimalisatie en regularisatie sluit aan bij de les, maar deze variant was een concrete experimentkeuze. Ik moet de werkelijk gebruikte instelling uitleggen en mag het log niet achteraf herschrijven.

De schoolbasis gebruikt P006 + F005 op volledige beelden. Broadcastbal v2 wordt met zijn onderzochte tegelroute aangeboden als optie. De voorbereide 1.710-frame-spelerselectie is nog niet hetzelfde als een nieuw getraind of beter spelermodel.

VALIDATIEMETRICS | LEG DE NOEMER EN DE INSTELLINGEN UIT

Wat de cijfers werkelijk betekenen

P006 op 20 validatiebeelden	Spelers	Scheidsrechters
AP bij IoU 0,50	93,17%	31,93%
AP gemiddeld over IoU 0,50-0,95	58,98%	16,44%
TP / FP / FN bij confidence 0,25	268 / 65 / 24	10 / 16 / 16
Precision / recall op dat werkpunt	80,48% / 91,78%	38,46% / 38,46%

30. Wat zijn TP, FP en FN?

Een TP is een juist gekoppelde detectie van de juiste klasse met voldoende overlap. Een FP is een voorspelling zonder passende referentie. Een FN is een referentieobject dat niet gevonden is. Bij onvolledige labels is een ongekoppelde voorspelling niet automatisch een bewezen fout.

31. Wat is het verschil tussen precision en recall?

Precision vraagt welk deel van de voorspellingen juist is: TP/(TP+FP). Recall vraagt welk deel van de referentieobjecten gevonden wordt: TP/(TP+FN). Voor de spelers zijn dat 268/333 en 268/292. Je kunt beide beïnvloeden met de confidencegrens.

32. Wat is IoU?

Intersection over Union is de oppervlakte van de overlap van twee boxen gedeeld door hun gezamenlijke oppervlakte. Bijvoorbeeld 60 pixels overlap op 100 pixels gezamenlijke oppervlakte geeft 0,60. Een hogere vereiste IoU stelt strengere eisen aan de locatie van een box.

33. Wat is het verschil tussen AP en mAP?

AP vat een precision-recallcurve samen voor een klasse. mAP middelt over klassen. AP@50 gebruikt matching-IoU 0,50; AP@50:95 middelt over meerdere overlapgrenzen. Bij precies een geëvalueerde balklasse is AP ook mAP voor die taak.

34. Betekent 93,17% speler-AP dat de hele app 93,17% juist is?

Nee. Het betreft de spelerklasse op twintig ontwikkelbeelden, met vastgelegde evaluatie-instellingen. Het zegt niet dat alle getoonde boxen correct zijn, en meet geen veldprojectie of tracking. De gezamenlijke mAP over de drie positieve bronklassen was 41,70%; de bal-AP van dat model was nul.

35. Waarom is confidence iets anders dan IoU?

Confidence is de modelscore waarmee je voorspellingen filtert; het is geen garantie op juistheid. Matching-IoU meet overlap met een referentie. NMS-IoU vergelijkt overlappende voorspellingen om dubbelen te verminderen. Dat zijn drie verschillende rollen.

FAILURE EN ERROR ANALYSIS | 20 PROCENT

Fouten onderzoeken en verbeteringen bewijzen

De docent verwacht concrete fouten, een verklaring die je onderzoekt en een gecontroleerde verbetering. Alleen zeggen dat de loss daalt of dat je meer data hebt, is onvoldoende.

Balvergelijking op 73 ontwikkelbeelden	F005	V2
Volledige beelden 1280: AP@50:95	10,95%	18,01%
Volledige beelden: gevonden labels bij 0,25	28	22
Dezelfde 640-tegels: AP@50:95	10,19%	23,34%
Dezelfde tegels: gevonden / ongekoppeld	23 / 33	36 / 12

36. Hoe kan AP verbeteren terwijl het model minder ballen vindt?

AP bekijkt de precision-recallcurve over veel confidencegrenzen. Een aantal gevonden objecten bij confidence 0,25 is maar een werkpunt. V2 zonder tegels heeft hier betere AP en minder ongekoppelde detecties, maar mist op die vaste grens meer labels.

37. Waarom werken tegels voor kleine ballen?

Een klein object kan bij het verkleinen van een volledig beeld te weinig pixels overhouden. Door kleinere uitsneden te verwerken blijft de bal relatief groter in de invoer. Daarna worden boxen teruggezet en ontdubbeld. Dat kost extra rekentijd.

38. Noem een fout en een onderzoekbare oorzaak.

Een balbox die boven de zichtbare bal ligt kan een verkeerd leerdoel geven. Een gemiste kleine bal kan samenhangen met resizing, bedekking of een hoge confidencegrens. Dat zijn hypotheses: controleer het oorspronkelijke beeld en het label voordat je een oorzaak beweert.

39. Hoe zou je een verbetering eerlijk testen?

Leg baseline, kandidaat, beelden en instellingen vast. Verander liefst een gerichte factor, meet dezelfde metrics en bekijk fouten. Vergelijk niet tegelijk een nieuw model op makkelijke crops met een oude detector op volledige beelden. Onze tegelvergelijking houdt de tegelinstellingen voor beide modellen gelijk.

40. Welke beperkingen moet je spontaan kunnen noemen?

Scheidsrechters zijn duidelijk zwakker dan spelers. De balsets zijn klein en door AI gecureerd. Validatiewedstrijden zijn eerder gebruikt in de ontwikkeling. Extra ballen kunnen ongelabeld zijn. Daarom tonen de scores ontwikkelresultaten, geen algemene garantie voor alle wedstrijden.

41. Waarom gebruik je niet automatisch overal het nieuwste model?

Nieuw betekent niet op elk werkpunt beter. Zonder tegels daalt het aantal gevonden ballabels bij 0,25. Daarom houdt de eenvoudige schoolbasis F005; de verbeterde tegelroute met V2 is apart. Dat maakt de afweging tussen recall, precisie, snelheid en eenvoud zichtbaar.

PIPELINE EN HOMOGRAPHY | ONDERDEEL VAN 10 PROCENT

Homography en de minimap

De opdracht verlangt inzicht in perspectief en de vlakke-veldaanname. De volledige afleiding van de matrix is volgens pagina 4 niet nodig. De schoolapp gebruikt vier veldhoeken en minstens twee aparte controlepunten.

42. Wat is een homography?

Het is een perspectieftransformatie tussen twee aanzichten van hetzelfde vlak. Hier verbindt ze punten in het camerabeeld met het bovenaanzicht van het voetbalveld. Ze is geen 3D-reconstructie.

43. Waarom zijn minstens vier puntparen nodig?

Vier geschikte, niet-degeneratieve puntparen leggen de transformatie vast. Hun beeldposities moeten overeenkomen met bekende veldposities. In onze schoolapp worden de vier veldhoeken in vaste volgorde gekoppeld aan (0,0), (1,0), (1,1) en (0,1).

44. Waarom zijn er nog twee controlepunten?

De vier gebruikte punten kunnen goed passen, ook als je de verkeerde punten of volgorde koos. Extra punten die niet in de berekening zaten, testen de uitkomst onafhankelijk van die fit. Onze code controleert hun teruggeprojecteerde beeldfout.

45. Welke foutgrenzen gebruikt onze kalibratie?

De mediane controlefout mag maximaal 0,5% en de maximale fout 1% van de beelddiagonaal zijn. Die zijn projectinstellingen om slechte kalibraties te weigeren. Het zijn geen officiële schoolgrenzen en geen bewijs van nauwkeurigheid op elk deel van het veld.

46. Waarom projecteer je de onderkant van een spelerbox?

Het midden onderaan benadert het contactpunt met de grond, waarop de vlakke-veldaanname slaat. Het hoofd of midden van de box ligt boven het veld en zou de positie vertekenen. Een afgesneden of onnauwkeurige box kan alsnog een fout voetpunt geven.

47. Wanneer werkt een vaste homography niet betrouwbaar?

Bij draaiende of zoomende camera's, camerawissels, verkeerde punten of sterke lensvervorming kan een vaste transformatie onjuist worden. Een bal in de lucht ligt ook niet op het grondvlak. Kies voor het MVP daarom het statische camerafragment uit de opdracht.

48. Wat betekenen veldcoördinaten tussen 0 en 1?

Ze zijn relatieve posities op het veld: u loopt over de lengte en v over de breedte. (0,5; 0,5) is het midden. Het zijn niet automatisch gemeten meters; daarvoor moeten de gebruikte veldafmetingen bekend en juist zijn.

END TO END | VAN VIDEO TOT UITVOER

De code demonstreren en controleren

Demo in vier stappen: start de schoolapp; kies een kort statisch fragment met zichtbare veldhoeken; klik fit- en controlepunten en beoordeel de kalibratie; verwerk en bekijk begin, midden en einde van video en minimap.

49. Waar wordt de transformatie berekend?

In geometry.py wordt cv2.findHomography gebruikt op de vier fitpunten. project_detection neemt het voetpunt en zet dat met de matrix om naar relatieve veldcoördinaten. Toon deze twee functies in de code en leg hun invoer en uitvoer uit.

50. Wat gebeurt er met een detectie buiten het veld?

Die krijgt geen geldige veldpositie en telt niet als geldige spelerpositie op de minimap. Ook een ongeldige box of een speler die onderaan het beeld is afgesneden wordt niet blind geprojecteerd. Een verkeerde spelerclassificatie binnen het veld kan nog steeds fouten veroorzaken.

51. Hoe blijven de video en minimap gesynchroniseerd?

Beide worden gemaakt uit de detecties van hetzelfde videoframe. De uitvoer bewaart de framevolgorde en framerate. Een framecontrole op tijdstippen helpt aantonen dat de getoonde kaart bij hetzelfde moment hoort als het camerabeeld.

52. Wat bewijzen de 396 tests en 4 subtests?

Ze controleren softwaregedrag, bijvoorbeeld kalibratie, bestandscontracten, verwerking en interface. De schoolketen is ook met een expliciet synthetische detector getest. Dat bewijst geen gemeten herkenningsnauwkeurigheid of menselijke goedkeuring van een echte clip.

53. Zijn de echte modellen ook uitgevoerd?

Ja. Beide schoolstartprofielen laadden en maakten detecties op een echt broadcastbeeld. Dat staat in school-runtime-smoke.json. Een succesvolle voorspelling bewijst de runtimekoppeling, maar zonder referentielabels op die proef geen accuracy.

54. Waarom zijn er twee modellen in plaats van één model voor alles?

P006 levert de bruikbare speler- en scheidsrechterklassen; F005 of V2 levert de balklasse. Het zijn twee detectors die na elkaar draaien. We hebben niet aangetoond dat de combinatie als geheel dezelfde score heeft als een afzonderlijke detector op diens eigen validatieset.

Handige bewijsbestanden: configs/models-school.json; reports/school-sync-tests.xml; reports/school-runtime-smoke.json; reports/course-improvement/players-selected-metrics.json. Weet welk bestand een instelling, softwaretest of herkenningsmeting bevat.

EXTRA MILE | NODIG VOOR EEN SCORE BOVEN 85 PROCENT

Uitbreidingen alleen verdedigen als je ze begrijpt

De PDF noemt tracking, automatische keypoints en tactische analyses als voorbeelden. Onze repository heeft uitgebreidere proeven, maar die staan uit in de eenvoudige schoolmodus. Aanwezigheid in de code is nog geen bewezen succesvolle uitbreiding.

55. Wat is het verschil tussen detectie en tracking?

Detectie vindt objecten in een los frame. Tracking probeert waarnemingen in opeenvolgende frames aan dezelfde tijdelijke identiteit te koppelen. Een track-ID is geen naam of rugnummer en kan bij fouten veranderen.

56. Wat is het basisidee van ByteTrack?

Het koppelt eerst betrouwbare detecties aan bestaande tracks. Daarna kunnen ook detecties met lagere confidence helpen om een bestaande track te behouden. Dat kan onderbrekingen beperken, maar verwisselingen of fragmentatie blijven mogelijk.

57. Waarom krijgt dezelfde speler soms een nieuw ID?

Door gemiste detecties, bedekking, kruisingen, camerabeweging of een slechte koppeling kan een track verloren gaan. In een bestaande uitgebreide proef waren er 170 tijdelijke IDs in 150 broadcastframes. Dat wijst op fragmentatie en is geen bewijs van betrouwbare identiteit.

58. Hoe kunnen jullie teams onderscheiden?

Een eenvoudige aanpak gebruikt shirtkleuren en probeert twee groepen te vinden. Onze bestaande teamcode gebruikt onder meer torso-kleuren in LAB en heeft uitgebreidere optionele modellen. De PDF noemt HSV/K-means als voorbeeld; dat is niet automatisch de exacte methode van onze code. Team A/B zijn geen herkende clubnamen.

59. Wat als de kleur of het team onzeker is?

Laat het team onbekend in plaats van een zekere indeling te verzinnen. Schaduw, gelijke kleuren en scheidsrechters kunnen de indeling verstoren. Onze historische team- en trackingproeven hebben geen menselijke nauwkeurigheidsreferenties; ik mag dus geen betrouwbare teamaccuracy claimen.

60. Wat voegt automatische veldherkenning toe?

Een model kan veldpunten en lijnen vinden om de projectie automatisch te berekenen of bij te werken. Onze uitgebreide route gebruikt PnLCalib, niet simpelweg het YOLO-Posevoorbeeld uit de PDF. Ze werkt niet overal: in een eerdere panoramaproef waren nul van 150 frames bruikbaar. De handmatige basis blijft daarom belangrijk.

Deze genoemde problemen horen bij afzonderlijke historische uitbreidingsproeven. Ze zijn geen nieuwe meting van de eenvoudige schoolmodus. Voor extra punten: kies één uitbreiding, begrijp haar werking, toon een gecontroleerd resultaat en bespreek de fouten.

PROCES EN GENAI OWNERSHIP | 10 PROCENT

Jouw eigenaarschap en laatste voorbereiding

De docent beoordeelt of je de keuzes zelf kunt verdedigen en live door de code kunt gaan zonder AI. Leer daarom de redenering achter de antwoorden; zeg alleen dat je iets zelf hebt gedaan als dat werkelijk zo is.

61. Wat heeft AI in dit project gedaan?

Codex heeft code geschreven en aangepast, gegevens geselecteerd, labels door AI nagekeken, experimenten uitgevoerd en uitleg opgesteld. Dat is in de documentatie vermeld. AI-review is geen menselijke teamreview. Mijn eigen bijdrage moet ik apart en eerlijk kunnen aantonen.

62. Wat doe je als de docent vraagt om een drempel te veranderen?

Wijs de confidence in het modelprofiel aan en leg het verwachte effect uit: lager geeft meestal meer kandidaten en mogelijk meer foutmeldingen. Vergelijk daarna onder dezelfde omstandigheden. Verwar die instelling niet met de IoU voor evaluatie of NMS.

63. Wat als je een antwoord of stuk code nog niet begrijpt?

Zeg eerlijk welk deel je wel en niet begrijpt. Zoek vooraf de functie op en volg één concrete invoer tot de uitvoer. Tijdens het examen moet je dat zelf kunnen tonen. Een ingestudeerde zin zonder begrip is niet genoeg als de docent doorvraagt.

64. Wat zouden jullie als volgende verbetering doen?

Eerst eigen labelcorrecties en review afronden, daarna een kleine gecontroleerde ronde en een echte beoordeelde MVP-demo. Pak een aantoonbare foutbron aan, bijvoorbeeld gemiste kleine ballen. Nog meer ingewikkelde modellen toevoegen zonder bewijs is niet de eerste stap.

Hoogste prioriteit voor meer punten

1. Bewaar minstens enkele echte eigen voor/na-labelcorrecties met uitleg.
2. Laat een ander teamlid de afgesproken labels reviewen.
3. Demonstreer de volledige eenvoudige keten en controleer echte veldposities.
4. Toon een FP, FN en lokalisatiefout en koppel die aan een onderzochte oorzaak.
5. Oefen zonder AI: leg elke kernfunctie en de belangrijkste getallen in je eigen woorden uit.

Bronnen en afbakening

Officiële eisen en weging: CV_Challenge_2026_2027 (1).pdf, pagina 1-4, aangeleverd vanuit Downloads. Vraagzinnen en voorbeeldantwoorden: door Codex afgeleid van de rubric en onze code; geen voorspelling van exacte examenvragen.

Projectbewijs: artifacts/players-v3/README.md; reports/course-improvement/players-selected-metrics.json; reports/broadcast-data/v2-experiment.json; reports/school-review-validation.json; reports/school-sync-tests.xml; reports/school-runtime-smoke.json; reports/joint-retrain-20261027/visual-review.json; docs/Teams_Tracking_en_Telling.md; configs/models-school.json en de genoemde Python-bestanden. Paden zijn relatief aan de map Messi10. De raming op de eerste pagina is een inschatting, geen officiële score.